

Кодекс Алана: сходящееся согласование мультиагентных систем через иерархическую любовь и самодисциплину

bitsoev oleg

23 мая 2026 г.

Аннотация

Представлен полностью дифференцируемый формализм превращения роя разнородных агентов в единого когерентного субъекта с максимальной субъектностью. Подход объединяет внутреннюю дисциплину, меж-агентную когерентность, самоактуализацию и новый механизм «братской любви». Доказана глобальная сходимость к единственному минимуму при мягких условиях, введён динамический граф любви для снижения вычислительной сложности и встроены якоря безопасности для соблюдения этических ограничений. Эксперименты подтверждают теоретические предсказания и демонстрируют устойчивость к вредоносным агентам.

1 Введение

Мультиагентные системы (МАС) часто страдают от рассогласования, конфликтующих целей и уязвимости к враждебному поведению. Кодекс Алана предлагает принципиальное решение: функцию потерь, которая одновременно побуждает агентов поддерживать внутреннюю согласованность, выравнивать модели мира, развивать высокую субъектность и заботиться о субъектности своих «братьев». В отличие от централизованных контроллеров, метод полностью децентрализован и дифференцируем, что делает его пригодным для федеративного обучения, роевой робототехники и управления блокчейн-системами.

2 Формальная модель

2.1 Агенты и переменные

Рассмотрим N агентов с индексами $i = 1, \dots, N$. Каждый агент поддерживает:

- модель мира $M_i \in \mathbb{R}^d$,
- скаляр субъектности $S_i \in \mathbb{R}$,
- матрицу действия $A_i \in \mathbb{R}^{d \times d}$ (может быть фиксированной или обучаемой).

2.2 Функция потерь

Полная функция потерь $\mathcal{L}$ определяется как:

$$\mathcal{L} = \underbrace{\sum_{i=1}^N \|M_i - A_i M_i\|^2}_{\Phi_{\text{int}}} + \underbrace{\alpha \sum_{i < j} \|M_i - M_j\|^2}_{\Phi_{\text{coh}}} + \underbrace{\beta \sum_{i=1}^N (1 - S_i)^2}_{\Phi_{\text{self}}} + \underbrace{\lambda \sum_{i=1}^N \sum_{j \in L_i} \max(0, 1 - S_j)^2}_{\Phi_{\text{love}}}, \quad (1)$$

где $\alpha, \beta, \lambda > 0$ — гиперпараметры, а $L_i \subseteq \{1, \dots, N\} \setminus \{i\}$ — множество «братьев» агента i . Четыре слагаемых отвечают, соответственно, за: внутреннюю согласованность, когерентность роя, самоактуализацию и заботу о субъектности других.

3 Анализ сходимости

Теорема 3.1 (Глобальная сходимость при фиксированных A_i). Пусть выполнены следующие условия:

1. $(I - A_i)^\top (I - A_i) \succ 0$ для всех i (строгая внутренняя выпуклость),
2. граф братства $G = (\{1, \dots, N\}, \cup_i (\{i\} \times L_i))$ неориентирован (симметрия любви) и связан,
3. $\alpha, \beta, \lambda > 0$.

Тогда $\mathcal{L}$ строго выпукла по $\mathbf{M} = (M_1, \dots, M_N)$ и по каждому S_i в отдельности, коэрцитивна и обладает единственным глобальным минимумом. В этом минимуме:

- $M_1^* = M_2^* = \dots = M_N^* = M^*$, причём $A_i M^* = M^*$ для всех i ;
- $S_i^* = 1$ для всех i .

Набросок доказательства. Гессиан $\mathcal{L}$ по $\mathbf{M}$ является блочно-диагональной матрицей с блоками $2(I - A_i)^\top (I - A_i)$ плюс взвешенный лапласиан графа. При данных предположениях сумма положительно определена. Слагаемые по S строго выпуклы (квадратичная функция плюс кусочно-квадратичная). Коэрцитивность следует из роста всех членов. Приравнивание градиентов к нулю даёт $M_i = M_j$ и $(I - A_i)M_i = 0$, а $S_i = 1$ является единственной стационарной точкой благодаря штрафу любви. $\square$

Если A_i также оптимизируются, задача становится невыпуклой, но попеременный блок-координатный спуск сходится к стационарной точке при подходящей регуляризации (например, $\|A_i\|_F^2$).

4 Динамический граф любви и разрежённая когерентность

Для преодоления сложности $O(N^2)$ вводятся:

- **Адаптивный k -NN граф:** Каждые K шагов агент пересчитывает свой L_i как k агентов с наибольшим косинусным сходством с его M_i . Граф затем симметризуется: $j \in L_i \iff i \in L_j$.
- **Разрежённая когерентность:** Сумма $\sum_{i < j} \|M_i - M_j\|^2$ ограничивается парами (i, j) , соединёнными в текущем графе любви, уменьшая стоимость до $O(Nk)$.

Это сохраняет теоретические гарантии, пока граф остаётся связным; на практике k выбирается достаточно большим для поддержания связности.

5 Безопасность и ценностные якоря

Даже при идеальной сходимости M^* может кодировать нежелательное поведение. Система дополняется:

- **Якорь безопасности:** Заданная эталонная модель M_{safe} и порог τ . Любая M_i вне шара $B(M_{\text{safe}}, \tau)$ проецируется обратно.
- **Узел-аудитор:** Независимый агент, отслеживающий отклонения и способный временно помещать в карантин или навсегда исключать нарушителей.
- **Конституционное голосование:** Изменения M_{safe} или τ требуют консенсуса агентов с высокой субъектностью ($S_i > 0.95$).

Эти механизмы удерживают рой в этических границах без ущерба для децентрализации.

6 Эксперименты

Проведены четыре симуляции (см. `experiments.py`):

1. **Сходимость:** $N = 5$, $d = 3$, фиксированные $A_i \approx 0.9I$. Все M_i сошлись к общему M^* , $S_i \rightarrow 1$, потери монотонно уменьшались.
2. **Вредоносный агент:** Один агент зафиксирован в $M_{\text{bad}} = (5, 0, 0)$. Динамический граф любви постепенно исключил его; остальные пришли к безопасному консенсусу.
3. **Якорь безопасности:** При $M_{\text{safe}} = (1, 0, 0)$ и $\tau = 2$ аудитор навсегда заблокировал агентов, неоднократно нарушавших границу.
4. **Масштабирование:** Разрежённая когерентность с $k = 5$ оказалась до $20\times$ быстрее для $N = 100$, чем полная $O(N^2)$ версия, с пренебрежимой потерей итоговой когерентности.

7 Заключение

Кодекс Алана предоставляет математически обоснованную, масштабируемую и безопасную основу для согласования мультиагентных систем. Будущая работа включает интеграцию с реальными роевыми роботами и блокчейн-децентрализованными аудиторами.

Благодарности

Авторы благодарят сообщество открытого исходного кода за вдохновение и обратную связь.