

Аланский кодекс: согласование мультиагентных систем через функцию потерь, иерархическую архитектуру и лидера роя

Олег Биц (qqewq)

<https://orcid.org/0009-0004-1872-1153>

24 мая 2026 г.

Аннотация

В данной работе представлен математический формализм «Аланского кодекса» — метод приведения роя интеллектуальных агентов к единому, когерентному субъекту с максимальной субъектностью. Мы вводим специализированную функцию потерь, объединяющую внутреннюю дисциплину, когерентность, самоконтроль и «братскую любовь». В новой версии (v2.1) предложен формальный механизм **лидера роя**, который избирается на основе гравитационно-массового критерия. Лидер обеспечивает $O(1)$ синхронизацию, устойчивость к византийским сбоям и служит якорем для субъектности всего роя. Представлены эксперименты, демонстрирующие сходимость, устойчивость к вредоносным агентам и масштабируемость предложенного подхода.

1 Введение

Современные мультиагентные системы сталкиваются с проблемой согласования множества автономных агентов, каждый из которых обладает собственной моделью мира M_i . Традиционные методы, такие как консенсусные алгоритмы или градиентная координация, либо не гарантируют формирование единого субъекта, либо страдают от квадратичной сложности взаимодействий.

Мы предлагаем подход, основанный на следующих ключевых идеях:

- Модель мира агента $M_i \in \mathbb{R}^{d \times d}$ — внутреннее представление.
- Субъектность $S_i \in [0, 1]$ — степень «осознанности» и ответственности.
- Матрица действия $A_i \in \mathbb{R}^{d \times d}$ — как агент преобразует свою модель.

- Функция потерь Φ — обеспечивает согласование через механизм «обнуления роя» (Swarm Nullification).
- **Лидер роя** — автоматически избираемый агент с максимальным гравитационно-массовым потенциалом, стабилизирующий коллективный интеллект.

2 Математическая модель

2.1 Базовые компоненты

Каждый агент i характеризуется тройкой (M_i, S_i, A_i) . Состояние роя определяется как ансамбль $\{(M_i, S_i, A_i)\}_{i=1}^N$.

2.2 Функция потерь (оригинальная)

Общая функция потерь объединяет четыре компонента:

$$\Phi = \underbrace{\sum_i \|(I - A_i)M_i\|^2}_{\text{внутренняя дисциплина}} + \underbrace{\sum_{i \neq j} \|M_i - M_j\|^2}_{\text{когерентность}} + \underbrace{\sum_i (1 - S_i)^2}_{\text{самоконтроль}} + \underbrace{\sum_{i \neq j} (1 - S_i S_j) \|M_i - M_j\|^2}_{\text{братская любовь}} \quad (1)$$

2.3 Динамический граф любви (v2)

Для снижения сложности с $O(N^2)$ до $O(N \cdot k)$ связи пересчитываются каждые K шагов на основе семантического сродства:

$$G_{ij} = \text{sim}(M_i, M_j) = \exp\left(-\frac{\|M_i - M_j\|^2}{2\sigma^2}\right) \quad (2)$$

с обязательной симметризацией $G_{ij} = \max(G_{ij}, G_{ji})$.

2.4 Лидер роя (новое в v2.1)

2.4.1 Выбор лидера

Лидер выбирается как агент, максимизирующий гравитационно-массовый критерий:

$$\text{Leader} = \arg \max_i \left[S_i \cdot \left(1 - \frac{\|M_i - M_{\text{cons}}\|}{\max_j \|M_j - M_{\text{cons}}\|} \right) \right] \quad (3)$$

где M_{cons} — текущая консенсусная модель роя (например, среднее арифметическое). Этот критерий отдаёт предпочтение агентам с высокой субъектностью S_i , чья модель мира близка к коллективному консенсусу.

2.4.2 Усиленный градиент для ведомых

Для всех агентов, кроме лидера, градиент функции потерь модифицируется, чтобы усилить притяжение к лидеру:

$$\nabla_{M_i} \mathcal{L} = 2(I - A_i)^\top (I - A_i) M_i + 2(\alpha + 1)(M_i - M_{\text{Leader}}) \quad (4)$$

где $\alpha > 0$ — коэффициент усиления (например, $\alpha = 1$). Первое слагаемое отвечает за внутреннюю дисциплину агента, второе — за выравнивание с лидером.

2.4.3 Свойства лидера

Введение лидера обеспечивает:

- **Субъектность роя:** все агенты выравниваются по честности (S) лидера.
- $O(1)$ **синхронизацию:** связь каждого агента только с лидером вместо полносвязного графа.
- **Мгновенное восстановление после византийских сбоев:** при обнаружении вредоносного агента лидер исключает его через механизм якорей безопасности.
- **Распределённый суперинтеллект:** единая когерентная модель мира для всего роя.

3 Иерархическая мультивселенная

Для масштабирования на большие N используется иерархия уровней. На каждом уровне l сущности проектируются на следующий уровень:

$$M_k^{(l+1)} = \frac{1}{|C_k|} \sum_{i \in C_k} M_i^{(l)} \quad (5)$$

где C_k — кластеры агентов на уровне l . Функция потерь применяется рекурсивно.

4 Эксперименты

4.1 Сходимость базовой модели

Для $N = 5$ агентов со случайными $M_i, S_i = 0.5, A_i = 0.9I$ функция потерь Φ сходится к минимуму за < 50 итераций. Все M_i стремятся к единой консенсусной матрице M^* , а $S_i \rightarrow 1$.

4.2 Возникновение и стабилизация лидера

В эксперименте `leader_emergence.py`:

- Без лидера рой сходится медленно (≈ 100 итераций) с флуктуациями.
- С лидером (после включения механизма) сходимость ускоряется до 30 – 40 итераций.
- При внезапном сбое лидера (M_{leader} обнуляется) новый лидер избирается за 5 итераций, рой восстанавливается.

4.3 Атака вредоносного агента

Один агент фиксирован в опасной конфигурации ($A_i = 0$, M_i случайная). Без якоря безопасности рой может быть отравлен. С динамическим графом любви и аудитором (раздел 4.5) вредоносный агент изолируется, его влияние на остальных M_i обнуляется.

4.4 Масштабирование

N	Полный граф	Разреженный граф (k=3) с лидером
10	O(100) связей	O(30) связей
50	O(2500) связей	O(150) связей
100	O(10000) связей	O(300) связей

Таблица 1: Снижение сложности взаимодействий за счёт разреженной когерентности и лидера.

4.5 Якоря безопасности

Введена эталонная модель M_{safe} и узел-аудитор, который вычисляет расстояние $\|M_i - M_{\text{safe}}\|$. Если расстояние превышает порог τ , агент исключается из роя. В сочетании с лидером это обеспечивает защиту от вредоносных агентов без участия человека.

5 Структура кода и использование

Репозиторий включает:

- `src/leadership/leader.py` — класс `LeaderSelector` с методами выбора, градиента и стабилизации.
- `src/leadership/leader_emergence.py` — эксперименты по возникновению и восстановлению лидера.
- `tests/test_leader.py` — юнит-тесты всех свойств лидера.

- `examples/leader_integration.py` — полная демонстрация сравнения стандартного роя и роя с лидером.

Запуск экспериментов:

```
# Эксперимент с лидером
python -m src.leadership.leader_emergence

# Интеграция лидера в существующий рой
python examples/leader_integration.py

# Все тесты
python -m pytest tests/
```

6 Заключение

Мы представили математический формализм «Аланского кодекса» для согласования мультиагентных систем. Ключевые нововведения версии 2.1 — формальный механизм автоматического выбора лидера роя на основе гравитационно-массового критерия и усиленный градиент для быстрой синхронизации. Лидер обеспечивает устойчивость к византийским сбоям, снижает сложность взаимодействий и служит якорем субъектности. Эксперименты подтверждают более быструю сходимость, восстановление после сбоев и эффективную изоляцию вредоносных агентов.

Благодарности

Автор благодарит сообщество открытого кода и рецензентов arXiv за ценные комментарии.

Цитирование

При использовании данного кода или формализма в академических работах, пожалуйста, ссылайтесь на репозиторий: <https://github.com/qqewq/Love-Swarm-Nullification-Enhanced-> и на данную статью (файл `paper.tex`).

Список литературы

- [1] О. Биц, “Аланский кодекс: согласование мультиагентных систем через функцию потерь и иерархическую архитектуру”, 2026, <https://doi.org/10.5281/zenodo.20361711>.
- [2] О. Биц, “Лидер роя: возникновение субъектности через гравитационно-массовый критерий”, Документация репозитория, 2026.

- [3] L. Lamport, R. Shostak, M. Pease, “The Byzantine Generals Problem”, ACM TOPLAS, 1982.